

Pekiştirmeli Öğrenme Tabanlı Konteyner Yerleştirici Tasarımı ve Eğitimi

Mehmet Andaç İyigör
Bursa Teknik Üniversitesi – Mekatronik Mühendisliği

Özet - Bu çalışmada, farklı boyutlara, çıkış önceliklerine ve içeriklere sahip konteynerlerin kargo olarak yüklenebilmek için limanlara uygun biçimde istiflenmesi problemi Epsilon-Greedy Q-learning yöntemi ile ele alınmıştır. Model, kargo alanından sırayla gelen konteynerleri limanlar arasında taşıyarak çıkış önceliklerine göre çıkarılabilecek duruma getirmeyi hedeflemektedir. Standart bir Q-Learning modeli, bu kadar farklı parametre ile başa çıkmakta zorlanacağından ödürü farkı optimizasyonlar kullanmak gerekmiştir ve eğitim sonuçları, bu kompleksiteye rağmen ödül değerlerinin zamanla iyileştiğini göstermektedir.

Anahtar Kelimeler: Q-learning, Q-table, Epsilon-Greedy, pekiştirmeli öğrenme, durum uzayı, konteyner

I. Giriş

Konteyner istifleme problemi, sınırlı depolama alanı bulunan lojistik sistemlerde önemli bir karar verme problemidir. Yanlış sırada yerleştirilen konteynerler, daha sonra çıkarılması gereken yüklerin üzerinde kalabilir ve ek taşıma maliyeti oluşturabilir. Bu nedenle konteynerlerin hem fiziksel kısıtlar hem de çıkış öncelikleri dikkate alınarak düzenlenmesi gerekir. Bu projede söz konusu problem, ajanın çevreyle etkileşerek uygun taşıma stratejileri öğrendiği bir pekiştirmeli öğrenme ortamı olarak modellenmiştir.

Sistemde kargo alanında bekleyen konteynerler sırayla alınabilmektedir. Ancak her konteynerin, kargo alanındaki konumundan bağımsız bir çıkış önceliği vardır. Bu durum, ajanın yalnızca sıradaki konteyneri işleyebilmesine rağmen nihai yerleşimde farklı bir öncelik düzenini hedeflemesi gerektiği anlamına gelir. Başarılı bir istifleme için daha erken çıkarılması gereken konteynerlerin üstte, daha geç çıkarılması gereken konteynerlerin ise alta bulunması gerekir. Her konteyner küçük, orta veya büyük boyutta olabilir. İstifleme kuralına göre daha büyük bir konteyner, daha küçük bir konteynerin üzerine yerleştirilemez. Bu nedenle bir konteyner yalnızca aynı boyuttaki veya kendisinden büyük bir konteynerin üzerine konulabilir. Bazı konteynerlerde ise, diğer konteynerler ile birlikte tutulmaması gereken toksik maddeler bulunmaktadır. Bu konteynerlerin de kendine özel ayrı bir limana istiflenmesi gerekecektir.

II. Ortam Tasarımı

Tasarlanan ortamda ajan, her adımda kargo alanındaki sıradaki konteyneri bir limana yerleştirebilir veya limanlar arasında en üstte bulunan konteyneri başka bir limana taşıyabilir. Limanlar yığın yapısı gibi davranmaktadır; yani bir limandan yalnızca en üstteki konteyner hareket ettirilebilir. Bu özellik, problemi klasik bir sıralama probleminden ayırmakta ve LIFO (Last In – First Out) yapısına dayalı ek bir hareket kısıtı oluşturmaktadır. Modelde toplamda 4 adet liman bulunmaktadır. Bu limanlardan bir tanesi, konteynerlerin taşınmasını kolaylaştırmak için bulunan ve boyut olarak daha küçük olan Geçici (Temporary) Limanı ($\bar{p}$), bir diğeryse de diğer konteynerler ile birlikte saklanmaması gereken toksik maddeler barındıran konteynerlerin istiflenmesi için ayrılmış Toksik Madde Limanıdır. Limanların boyutu (p) istiflenmesi gereken konteyner sayısına (n) bağlı şekilde değişmektedir.

$$p = \left\lfloor \frac{n+1}{2} \right\rfloor, \quad \bar{p} = \left\lfloor \frac{p+1}{2} \right\rfloor$$

Bir hareketin legal kabul edilebilmesi için hedef limanın kapasitesinin dolmamış olması ve boyut kuralının sağlanması gerekir. Ayrıca normal konteynerlerin toksik madde limanına yerleştirilmesi engellenmiştir. Bu kurallar sayesinde ortam, yalnızca öncelik sırasına değil, aynı zamanda fiziksel ve güvenlik temelli kısıtlara göre de değerlendirme yapmaktadır. Başarı koşulu, kargo alanının tamamen boşaltılması, geçici limanın boş kalması ve tüm limanların öncelik, boyut ve toksik madde kurallarına uygun şekilde düzenlenmiş olmasıdır.

Remaining cargo:				
[04-L]	[01-L]	[00-M]	[05-L]	[03-M]
[02-S]				
Level	Port 1	Port 2	Temp	Toxic
TOP	[]	[]	[]	[]
	[]	[]	[]	[]
BOTTOM	[]	[]	[]	[]

Şekil 1: Liman ve kargo gösterimi

III. Durum ve Eylem Uzayı

Modelin eylem uzayı, 2 farklı gruba ayrılmış toplam 16 farklı eylemden oluşmaktadır. Kargo alanından limana konteyner yerleştirme (0: Birinci limana yerleştir, 1: İkinci limana yerleştir, 2: Geçici limana yerleştir, 3: Toksik madde limanına yerleştir) ve limanlar arası konteyner taşıma (4-6: Birinci limandan ikinci/geçici/toksik limana taşı, 7-9: İkinci limandan birinci/geçici/toksik limana taşı, 10-12: Geçici limandan birinci/ikinci/toksik limana taşı, 13-15: Toksik limandan birinci/ikinci/geçici limana taşı). Bu sabit eylem uzayı, limanların ve konteynerlerin durumundan bağımsız bir şekilde ajanın yapabileceği bütün eylemleri kapsamaktadır. Model bu eylemlerin seçilmesinde aktif bir limitasyon uygulamaya da illegal sayılan hamlelere (mesela birinci liman boş olmasına rağmen birinci limandan konteyner taşımak gibi) yüklü miktarda ceza uygulayarak ajanın bu hamleleri anlık durumu göz önünde bulundurarak seçmesi için teşvik ediyor.

Modelin boyuttan ve istiflenmesi gereken konteynerlerdeki varyasyondan ödürü, model çok büyük boyutta bir durum uzayına sahiptir. Eğer ki bütün konteynerlerin özelliklerini ve konumlarını ele alan basit bir durum hesabı yapacak olursak:

$$S_{total}(n) = (3 * 2)^n * (n + 3p + \bar{p})^n$$

Bu metodun en büyük iki zayıflığı, her durumun özgün olması ve oluşması imkansız olan durumlara dikkat etmemesidir (konteynerlerin aynı konuma istiflenmesi veya küçük bir konteyneri büyük bir konteynerin altına koymak gibi). Q-table boyutu büyüdükçe tabloda arama yapmak ve bu sebeple de eğitim için gereken süre, tablonun hafızada kapladığı alan ve eğitim sırasında değerlendirilmesi gereken durum sayısı artacaktır. Bu sorunları gidermek adına konteynerlerin ve limanların anlık durumunu enkode etmekten istenilen hedefe ulaşmak için gereken değişiklikleri özetleyen bir durum temsili kullanılmıştır. Bu yeni modelde, kargoda en önde bulunan konteynerin özellikleri (C_n), en öncü olan konteynerin konumu (C_f) ve limanların her birinin durumu (P_1, P_2, P_{tp}, P_{tx}) ele alınmaktadır.

$$C_n = (1 + 2n)$$

$$C_f = 4$$

$$P_1 = P_2 = 2 * 3 * 2 * 2 * 4 * 2 = 192$$

$$P_{tp} = 2 * 3 * 3 = 18$$

$$P_{tx} = 2 * 3 * 2 * 4 * 2 = 96$$

$$S_{total}(n) = C_n * C_f * P_1 * P_2 * P_{tp} * P_{tx}$$

Bu sayede model, birden fazla durum hakkında genelleme yaparak öğrenme aşamasında eksiklik olması ihtimalini azaltıyor ve çözüme ulaşmak için farklı durumları birkaç farklı çözüm stratejilerine indirgeyebiliyor.

IV. Q-Learning Yöntemi ve Parametreleri

Bu çalışmada ajanı eğitmek için Q-Learning algoritması kullanılmıştır. Q-Learning, ajanın sadece anlık durumu göz önünde bulundurarak en fazla ödül miktarını elde etmesini sağlayacak hamleleri seçerek istenilen bir işi yapmayı öğrenmesini hedefleyen bir pekiştirmeli öğrenme yöntemidir. Bu yöntem, geçiş olasılıklarının önceden bilinmesini gerektirmediği için kural tabanlı ancak karmaşık ortamlarda uygulanabilir bir yaklaşımdır. Q-değerleri, mevcut durum ve seçilen eylem çiftinin beklenen uzun vadeli değerini temsil eder. Ajan bir eylem gerçekleştirdiğinde hem anlık ödülü hem de yeni durumda elde edilebilecek en yüksek tahmini değeri dikkate alarak Q-table üzerinde güncelleme yapar. Bu yapı sayesinde ajan, yalnızca kısa vadede ödül getiren hareketleri değil, görevin tamamlanmasına katkı sağlayan uzun vadeli stratejileri de öğrenebilir.


Proje öğrenme oranı $\alpha = 0.2$, indirim faktörü $\gamma = 0.95$ olarak belirlenmiştir. Öğrenme oranı yeni bilginin mevcut Q-değerini ne kadar değiştireceğini belirlerken, indirim faktörü gelecekteki ödüllerin bugünkü karar üzerindeki etkisini kontrol etmektedir.

$$Q(s,a) = (1 - \alpha) * Q(s,a) + \alpha * (r + \gamma * \max_{a'} Q(s'))$$

Şekil 3 ve Şekil 4: Senaryo oluşturma fonksiyonu

VI. Eğitim Süreci ve Bulgular

Eğitim sürecinde en önemli zorluk, genişleyen durum uzayı nedeniyle ajanın yeterli sayıda anlamlı durumu ziyaret etmesinin zorlaşmasıdır. Bu nedenle güncel modelin eğitimi için, önceki daha basit sürümüne göre daha fazla episode gerektirmektedir. Buna rağmen yapılan optimizasyonlar sayesinde ödül değerlerinde zaman içinde iyileşme gözlemlenmiştir. Dictionary tabanlı Q-table, belleğin daha verimli kullanılmasını sağlamış; çözülebilir senaryo üretimi ise ajanın imkânsız durumlar üzerinde zaman kaybetmesi ve yanlış eylemleri öğrenmesi ihtimallerini azaltmıştır. Bu iki düzenleme, öğrenme sürecinin daha istikrarlı ilerlemesine katkıda bulunmuştur. Eğitim çıktıları incelendiğinde ajanın başlangıçta rastgele ve çoğu zaman verimsiz hareketler yaptığı, ancak eğitim ilerledikçe daha kısa ve hedefe yönelik hareket dizilerine yöneldiği görülmektedir. Bununla birlikte test aşamasında bazı durumlarda ajan illegal eylemlere veya durumu değiştirmeyen hamlelere takılabilmektedir. Bu durum, Q-table tabanlı yöntemlerde özellikle büyük durum uzaylarında karşılaşılabilecek bir sınırlılık olarak değerlendirilebilir.



Şekil 5 ve Şekil 6: Eğitim sürecindeki ortalama ödül değerleri

Bu çalışmada, konteyner sıralama ve istifleme problemi Q-Learning algoritması ile modellenmiş ve farklı kısıtlar altında çalışan bir ajan geliştirilmiştir. Konteyner boyutu, toksik madde ayrımı, liman kapasitesi ve geçici depolama alanı gibi özellikler probleme gerçekçi kısıtlar eklemiştir. Bu kısıtlar durum uzayını büyütmüş olsa da, sparse Q-table ve çözülebilir senaryo üretimi sayesinde eğitim süreci uygulanabilir hâle getirilmiştir. Sonuçlar, ajanın zaman içinde daha iyi ödül değerlerine ulaşabildiğini ve belirli senaryolarda anlamlı yerleştirme stratejileri öğrenebildiğini göstermektedir.

V. Başlangıç Senaryosu

Başlangıç senaryolarının tamamen rastgele üretilmesi, bazı durumlarda çözülemez örneklerin ortaya çıkmasına neden olabilmektedir. Bu, sadece çıkış önceliklerinin bulunduğu eski model için problematik olmasa da şu an modelde bulunan faktörlerden ötürü ele alınması gereken bir problemdir. Böyle bir durumda ajan, teorik olarak başarıya ulaşamayacağı bir senaryodan öğrenmeye çalışır ve yaptığı her hamle ile cezalandırılır. Bu sorunu gidermek adına kargoyu basit bir shuffle (karıştırma) fonksiyonundan geçirmektesse önce istenilen sonucu oluşturup geriye doğru legal adımlar yaparak bir başlangıç koşulu oluşturulmaya çalışılmıştır. Böylece elde edilen başlangıç durumunun en az bir çözümünü olduğu garanti edilir. Bu yöntem aynı zamanda senaryo zorluluğu kontrol etmeyi de mümkün kılar. Geriye doğru yapılan karıştırma hareketlerinin sayısı artırdıkça başlangıç durumu final çözümden uzaklaşır ve ajanın görevi tamamlamak için daha uzun bir eylem dizisi öğrenmesi gerekir. Böylece eğitim seti hem çözülebilir hem de yeterince çeşitli hâle getirilebilir.

[illegible]